Text_Mining_Reuters

Montse Figueiro 4 de julio de 2016

Prepocesamiento con el Paquete tm

Vamos a terminar construyengo una matriz de frecuencias, las filas son documentos, las entradas son el numero de veces que ocurren, las columnas son terminos, puedes estudiar classificación, clustering, detección de temas, representación grafica, nubes palabras. Los documentos pueden ser novelas, estas matrices son bags of words. es convertirlo en conteo de palabras, con eso destruyes el texto pero puedes hacer ciertas cosas. A veces te quedas con trigramas (trios de palabras) o n-gramas (n palabras consecutivas en el texto) Los trigramas son más utiles en el inglés (muy estructurado), proque todo está hecho para le inglés y el español es un poco diferente.

ngrams

Matrices de frecuencias:

Pasos a Seguir:

- tokenizacion: parte los textos en palabras. Las palabras que componen un texto, cuales son los separadores posibles, hay un problema por ejemplo espresiones como "estar en los cerros de úbeda" es una expresion como una sola palabra. Nombres propios es una sola palabras "Tribunal de cuentas" es una sola palabra, esto exige tener un buen "ner" named entity recognition, que te permita detectar objetos sujetos cuyo nombre nombres consta de varias palabras. Coges el BOE y quieres saber de que se está hablando. Es más complicado de llo que parece. Mayusculas separadas por un de, hay un diccionario de nombres propios y los encuentra....
- Eliminación palabras comunes (y, la, a), son demasiado comunes y no sirven para los analisis, hay listas por idiomas estas palabras no aportan nada, son frecuentes en todos losdocumentos, TF-IDF es una medida que da peso a los términos que aparecen frecuentemente pero que quieres que aparezcan no en todos los documentos sino también en un subconjunto de documentos. TF- term frecuency IDF-inverse document frequency que aparezca en pocos documentos. quieres dar más peso a uno sobre otro, quieres calibrar que parte es más interesante. cogemos texto, quitamos palabras comunes, tienen el TFIDF más alto.
- Lematización: buscar raíz de las palabras (casa puede ser de casa, de casar) el verbo puede tener mas de 100 formas distintas en español, el españoles muy flexible morfológicamente, una palabra suelta no sabes que raiz tiene "casas", es casa o casar? hay metodos basados en reglas, snowball. Otros basados en diccionarios, es una busqueda directamente en diccionario, solo que te puede dar varias raices. Basados en máquinas de estados finitos. puedes tener todos los verbos conjugados (esto lo hace el movil cuando predice).

Snowball: lo usan mucho, es un algoritm, te da una coleccion de raíz de palabras, en algunos casos coincide en otros no. Es muy bruto.

Si quieres contar el numero de palabras en un discurso, con Snowball no queda bien, hay palabras que las utilizas con varios generos, no las suma.

• sinónimos: cuando escribes tratas de no repetir palabras, te gustaría deshacer eso, hay que utilizar diccionarios.

Con esto ya tenemos la matriz de frecuencias.

Hoy te casas, hoy es adverbio, te es pronombre y casas puede ser nombre overbo, te calcula las probabilidades de que sea una opcion u otra. Usando modelos de Markov

Librerias

```
library(tm)

## Loading required package: NLP

library(RColorBrewer)
library(wordcloud)
```

Corpus Sources and Readers:

```
getSources()
                                           "URISource"
                                                             "VectorSource"
## [1] "DataframeSource" "DirSource"
## [5] "XMLSource"
                         "ZipSource"
getReaders()
  [1] "readDOC"
                                  "readPDF"
##
  [3] "readPlain"
                                  "readRCV1"
## [5] "readRCV1asPlain"
                                  "readReut21578XML"
   [7] "readReut21578XMLasPlain" "readTabular"
                                  "readXML"
## [9] "readTagged"
```

Data reuters

```
data("acq")
acq[[1]]

## <<PlainTextDocument>>
## Metadata: 15
## Content: chars: 1287

ruta<- system.file("texts", "acq", package = "tm")
ruta</pre>
```

[1] "D:/Users/msi/Documents/R/win-library/3.3/tm/texts/acq"

```
reuters <- VCorpus(DirSource(ruta),</pre>
                  readerControl = list(reader = readReut21578XMLasPlain))
reuters[[1]]
## <<PlainTextDocument>>
## Metadata: 16
## Content: chars: 1287
Inspect one document inside Corpus
inspect(reuters[1])
## <<VCorpus>>
## Metadata: corpus specific: 0, document level (indexed): 0
## Content: documents: 1
##
## [[1]]
## <<PlainTextDocument>>
## Metadata: 16
## Content: chars: 1287
str(reuters[1])
## List of 1
## $ 10:List of 2
     ..$ content: chr "Computer Terminal Systems Inc said\nit has completed the sale of 200,000 shares
               :List of 16
     ..$ meta
     .. ..$ author
                        : chr(0)
##
     .. ..$ datetimestamp: POSIXlt[1:1], format: NA
##
     .. ..$ description : chr ""
##
##
     .... heading : chr "COMPUTER TERMINAL SYSTEMS <CPML> COMPLETES SALE"
##
     .. ..$ id
                        : chr "10"
     ....$ language : chr "en"
##
     ....$ origin : chr "Reut ....$ topics : chr "YES"
##
                       : chr "Reuters-21578 XML"
##
     .... $\text{lewissplit} : \text{chr "TRAIN"}
##
     ....$ cgisplit : chr "TRAINING-SET"
##
##
     .. ..$ oldid
                        : chr "5553"
##
     .. .. $ topics_cat : chr "acq"
     .. ..$ places
                        : chr "usa"
##
##
     .. ..$ people
                        : chr(0)
                        : chr(0)
##
     .. ..$ orgs
##
     ....$ exchanges : chr(0)
     ....- attr(*, "class")= chr "TextDocumentMeta"
##
    ..- attr(*, "class")= chr [1:2] "PlainTextDocument" "TextDocument"
  - attr(*, "class")= chr [1:2] "VCorpus" "Corpus"
```

reuters[[1]]\$content

strwrap(reuters[[1]])

[1] "Computer Terminal Systems Inc said\nit has completed the sale of 200,000 shares of its common\n

```
[1] "Computer Terminal Systems Inc said it has completed the sale of"
##
    [2] "200,000 shares of its common stock, and warrants to acquire an"
   [3] "additional one mln shares, to <Sedio N.V.> of Lugano, Switzerland"
##
   [4] "for 50,000 dlrs. The company said the warrants are exercisable"
   [5] "for five years at a purchase price of .125 dlrs per share."
##
   [6] "Computer Terminal said Sedio also has the right to buy additional"
##
##
   [7] "shares and increase its total holdings up to 40 pct of the"
##
   [8] "Computer Terminal's outstanding common stock under certain"
   [9] "circumstances involving change of control at the company. The"
## [10] "company said if the conditions occur the warrants would be"
## [11] "exercisable at a price equal to 75 pct of its common stock's"
## [12] "market price at the time, not to exceed 1.50 dlrs per share."
## [13] "Computer Terminal also said it sold the technolgy rights to its"
## [14] "Dot Matrix impact technology, including any future improvements,"
## [15] "to <Woodco Inc> of Houston, Tex. for 200,000 dlrs. But, it said it"
## [16] "would continue to be the exclusive worldwide licensee of the"
## [17] "technology for Woodco. The company said the moves were part of"
## [18] "its reorganization plan and would help pay current operation costs"
## [19] "and ensure product delivery. Computer Terminal makes computer"
## [20] "generated labels, forms, tags and ticket printers and terminals."
## [21] "Reuter"
```

Un Corpus es una lista de documentos; cada documento tiene el texto y un conjunto de metadatos (que no usaremos)

Transformaciones: tm map aplica una función a cada documento

```
reuters <- tm_map(reuters, content_transformer(tolower))#tolower hay que meterla dentro sino no funcion
#pasa todas las palabras a minúsculas
reuters <- tm_map(reuters, removePunctuation)#elimina comas y puntos
reuters <- tm_map(reuters, removeWords, stopwords("en"))#quitamos palabras stopwords,trae una lista, so
#comunes sin importancia en el análisis.

reuters[[1]]$content

## [1] "computer terminal systems inc said completed sale 200000 shares common stock warrants a
class(reuters)

## [1] "VCorpus" "Corpus"
```

reuters <- tm_map(reuters, stripWhitespace) # quitar los espacios en blanco que están de más sobre cada

Raíz de las palabras con Snowballc

```
library(SnowballC)
Snowreuters <- tm_map(reuters[1:10], stemDocument)
Snowreuters[[1]]$content</pre>
```

[1] "comput termin system inc said complet sale 200000 share common stock warrant acquir ad

WordCloud reuters



##word matrix

```
matrix <- DocumentTermMatrix(reuters) #matriz original de frecuencias findFreqTerms(matrix, 100)#aparecen mas de 100 veces
```

```
## [1] "dlrs" "said"
```

findFreqTerms(matrix,50)#aparecen más de 50 veces ## [1] "company" "dlrs" "inc" "mln" "pct" "reuter" "said" ## [8] "shares" freq.term <- findFreqTerms(matrix,lowfreq = 15)</pre> freq.term ## [1] "1986" "acquire" "agreed" "also" "american" ## [6] "analysts" "bank" "business" "cash" "common" "group" ## [11] "company" "corp" "dlrs" "express" "management" "market" "mln" ## [16] "inc" "new" "pct" "reuter" ## [21] "offer" "one" "rmj" ## [26] "said" "securities" "share" "shares" "shearson" ## [31] "stake" "stock" "value" "viacom" "will" Frecuency Words matrixreuters <- as.matrix(matrix)</pre> frequency <- colSums(matrixreuters)</pre>

```
frequency <- sort(frequency, decreasing=TRUE)</pre>
head(frequency,10)
##
      said
              dlrs
                       pct
                               mln company
                                                                      stock
                                               inc shares reuter
##
      186
              100
                       70
                                65
                                        63
                                               53
                                                        52
                                                                50
                                                                         46
##
     will
##
       35
```

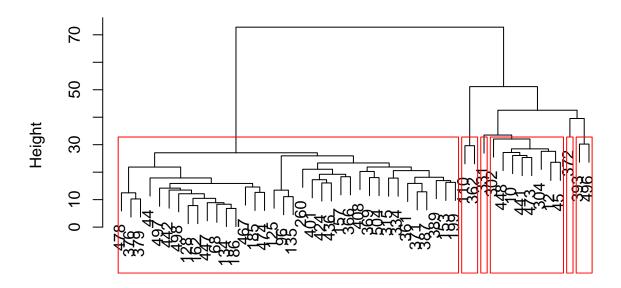
```
wordcloud(names(frequency), frequency ,min.freq=15, colors=brewer.pal(6, "Dark2"))
```



###Frecuency words removing sparse Terms (this terms apears in a few documents)

```
matrixreuters2<- removeSparseTerms(matrix, sparse = 0.95)
m2 <- as.matrix(matrixreuters2)
distMatrix <- dist(scale(m2))
fit <- hclust(distMatrix, method = "ward.D")
plot(fit)
rect.hclust(fit, k = 6) # cut tree into 6 clusters</pre>
```

Cluster Dendrogram



distMatrix hclust (*, "ward.D")

```
frequency2 <- colSums(m2)</pre>
frequency2 <- sort(frequency2, decreasing=TRUE)</pre>
head(frequency2,10)
##
      said
              dlrs
                                mln company
                                                                       stock
                       pct
                                                 inc
                                                     shares
                                                              reuter
               100
                        70
                                 65
##
       186
                                                 53
                                                          52
                                                                  50
                                                                          46
##
      will
##
        35
inspect(matrixreuters2[1:10,1:10])
## <<DocumentTermMatrix (documents: 10, terms: 10)>>
## Non-/sparse entries: 11/89
## Sparsity
## Maximal term length: 12
## Weighting
                     : term frequency (tf)
##
##
        Terms
## Docs 125 1985 1986 1987 200 acquire acquired acquisition acquisitions
##
     10
                                                                          3
##
     12
     44
         0
                     0
                             0
                                       0
                                                0
                                                                          0
##
```

1

##

##

45

68

0 1

0

```
##
     96
            0
                  0
                        0
                                  0
                                                                    0
##
     110
            0
                        0
                             0
                                  1
                                           0
                                                      0
                                                                    0
                                                                                   1
                  1
                                                      0
                                                                                  0
##
     125
            0
                             0
                                  0
                                           0
                                                                    0
     128
                             0
                                 0
                                           0
                                                     0
                                                                    0
                                                                                  0
##
            0
                  0
                        0
##
     134
            0
                        0
                             0
                                  0
                                           0
                                                      0
                                                                    0
                                                                                   0
##
        Terms
## Docs added
     10
##
##
     12
              0
##
     44
              0
##
     45
##
     68
              0
##
     96
              0
##
     110
##
     125
              0
##
     128
              0
##
     134
              0
```

TP-IDF

Normaliza le quita importancia a las palabras que aparecen repetidas en muchos documentos. Le quita peso.

```
reuters.norm <- weightTfIdf(matrix)</pre>
inspect(reuters.norm[1:10,1:10])
## <<DocumentTermMatrix (documents: 10, terms: 10)>>
## Non-/sparse entries: 2/98
## Sparsity
                      : 98%
## Maximal term length: 6
## Weighting
                      : term frequency - inverse document frequency (normalized) (tf-idf)
##
##
        Terms
## Docs 05165 0523
                          100 10000 100000
                                                   101 105 1078 110 1100
                  0 0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                   0
                                                                        0
##
     10
             0
                                                         0
##
     12
             0
                  0.0000000
                                  0
                                          0.00000000
                                                         0
                                                               0
                                                                   0
                                                                        0
##
     44
             0
                  0 0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                  0
                                                                        0
##
     45
             0
                  0 0.0000000
                                  0
                                          0 0.02577103
                                                         0
                                                              0
                                                                  0
                                                                        0
##
     68
             0
                  0 0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                  0
                                                                        0
                  0 0.1132648
                                  0
                                                              0
                                                                  0
                                                                        0
##
     96
             0
                                          0.00000000
                                                         Ω
##
     110
                  0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                 0
                                                                        0
##
     125
                  0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                 0
                                                                        0
             0
                                                         0
##
     128
             0
                  0.0000000
                                  0
                                          0.00000000
                                                              0
                                                                        0
##
                  0 0.0000000
                                   0
                                          0 0.00000000
                                                              0
                                                                        0
     134
             0
reuters.norm.matrix <- as.matrix(reuters.norm)</pre>
frequency.norm <- colSums(reuters.norm.matrix)</pre>
frequency.norm <- sort(frequency.norm, decreasing=TRUE)</pre>
head(frequency.norm,10)
##
      shares
               liebert
                             dlrs
                                                            mln
                                        rmj
                                                 corp
```

La matriz de resultados normalizados la podemos pasar a data.frame

```
Res <- as.data.frame(inspect(reuters.norm[,c("said","company")]))</pre>
## <<DocumentTermMatrix (documents: 50, terms: 2)>>
## Non-/sparse entries: 27/73
## Sparsity
                       : 73%
## Maximal term length: 7
## Weighting
                      : term frequency - inverse document frequency (normalized) (tf-idf)
##
##
        Terms
## Docs
         said
                   company
     10
##
            0 0.027352883
##
     12
            0 0.011545048
##
     44
            0 0.00000000
##
     45
            0 0.016236871
##
     68
            0 0.00000000
##
            0 0.00000000
     96
##
     110
            0 0.012996618
##
     125
            0 0.014573257
##
            0 0.00000000
     128
            0 0.037040362
##
     134
            0 0.00000000
##
     135
##
     153
            0 0.015595942
##
            0 0.029965237
     157
##
     162
            0 0.000000000
##
     185
            0 0.00000000
##
     186
            0 0.049387149
##
     199
            0 0.00000000
##
     260
            0 0.019325406
##
     302
            0 0.007377334
            0 0.00000000
##
     304
##
     315
            0 0.00000000
##
            0 0.004857752
     331
##
     334
            0 0.00000000
##
            0 0.000000000
     361
##
            0 0.005437117
     362
##
     366
            0 0.009988412
##
     369
            0 0.014110614
##
     371
            0 0.013268189
##
     372
            0 0.020073486
##
            0 0.040407668
     376
##
     379
            0 0.000000000
            0 0.00000000
##
     387
##
     389
            0 0.000000000
##
     393
            0 0.011696956
##
            0 0.021949844
     401
##
     408
            0 0.008386497
##
            0 0.000000000
     424
##
     436
            0 0.00000000
##
     441
            0 0.010974922
##
     442
            0 0.00000000
##
            0 0.000000000
     447
```

```
0 0.024557146
##
     448
##
     467
            0 0.000000000
##
     473
           0 0.025159491
##
     474
           0 0.018142218
##
     478
            0 0.000000000
##
     496
           0 0.017545435
     497
           0 0.057976219
##
            0 0.000000000
     498
     504
            0 0.000000000
```

Res[,"company"]

```
## [1] 0.027352883 0.011545048 0.000000000 0.016236871 0.0000000000  
## [6] 0.000000000 0.012996618 0.014573257 0.000000000 0.037040362  
## [11] 0.000000000 0.015595942 0.029965237 0.000000000 0.000000000  
## [16] 0.049387149 0.000000000 0.019325406 0.007377334 0.000000000  
## [21] 0.00000000 0.004857752 0.000000000 0.000000000 0.005437117  
## [26] 0.009988412 0.014110614 0.013268189 0.020073486 0.040407668  
## [31] 0.00000000 0.000000000 0.0011696956 0.021949844  
## [36] 0.008386497 0.000000000 0.000000000 0.010974922 0.000000000  
## [41] 0.000000000 0.024557146 0.000000000 0.025159491 0.018142218  
## [46] 0.000000000 0.017545435 0.057976219 0.000000000 0.000000000
```

Words correlation

findAssocs(matrix, "dlrs", 0.6)

##	\$dlrs			
##	least	valued	rivals	unless
##	0.84	0.83	0.82	0.82
##	cash	takeover	provide	mln
##	0.81	0.78	0.77	0.74
##	revised	118	150	175
##	0.73	0.72	0.72	0.72
##	195	2275	295	3850
##	0.72	0.72	0.72	0.72
##	475	592	6881800	agreements
##	0.72	0.72	0.72	0.72
##	besides	bidding	bids	chain
##	0.72	0.72	0.72	0.72
##	commitment	confident	confidentiality	consist
##	0.72	0.72	0.72	0.72
##	consisting	contains	contribution	dedham
##	0.72	0.72	0.72	0.72
##	disclose	documents	drawn	face
##	0.72	0.72	0.72	0.72
##	fenner	formal	groups	half
##	0.72	0.72	0.72	0.72
##	information	keep	leads	limited
##	0.72	0.72	0.72	0.72
##	lynch	massbased	merrill	monthlong

##				
##	newly	onefifth	operator	pierce
##	0.72	0.72	0.72	0.72
##	portion	purchases	purpose	records
##	0.72	0.72	0.72	0.72
##	redstone	redstones	sec	secret
##	0.72	0.72	0.72	0.72
##	separate	set	smith	submitted
##	0.72	0.72	0.72	0.72
##	sumner	sweeten	sweetened	syndicate
##	0.72	0.72	0.72	0.72
##	theater	toward	underwrite	underwriting
##	0.72	0.72	0.72	0.72
##	vying	war	financing	raise
##	0.72	0.72	0.70	0.70
##	committed	inc	share	4050
##	0.68	0.68	0.68	0.65
##	750	called	committee	eight
##	0.65	0.65	0.65	0.65
##	viacom	viacoms	later	proposed
##	0.65	0.65	0.64	0.64
##	two	contribute	offer	provided
##	0.63	0.62	0.62	0.62
##	earlier			
##	0.60			

findAssocs(matrix, "said", 0.6)

##	\$said			
##	company	analysts	part	stock
##	0.75	0.74	0.72	0.70
##	316	aftertax	brothers	chairmen
##	0.69	0.69	0.69	0.69
##	considered	contributed	created	divisions
##	0.69	0.69	0.69	0.69
##	eckenfelder	expand	express	got
##	0.69	0.69	0.69	0.69
##	highly	internal	lane	larry
##	0.69	0.69	0.69	0.69
##	lehman	move	place	positions
##	0.69	0.69	0.69	0.69
##	prudentialbache	remained	rumors	selling
##	0.69	0.69	0.69	0.69
##	sense	silent	spinoff	unlikely
##	0.69	0.69	0.69	0.69
##	vacant	shearson	american	reflect
##	0.69	0.68	0.66	0.66
##	operating	services	fully	market
##	0.65	0.64	0.63	0.63
##	believe	chief	however	officer
##	0.62	0.62	0.62	0.62
##	several	shearsons	speculated	spinning
##	0.62	0.62	0.62	0.62
##	strong	future	also	

0.62 0.61 0.60

findAssocs(matrix, "pct", 0.6)

##	\$pct				
##	stake	increased	interests	rights	option
##	0.74	0.69	0.69	0.66	0.63
##	cost	key	126	148	1984
##	0.62	0.62	0.61	0.61	0.61
##	341	400	424	455	494
##	0.61	0.61	0.61	0.61	0.61
##	activities	alfa	alfs	amounted	arms
##	0.61	0.61	0.61	0.61	0.61
##	asea	asts	atlas	back	building
##	0.61	0.61	0.61	0.61	0.61
##	•	concentrating	copco	core	crowns
##	0.61	0.61	0.61	0.61	0.61
##	defend	diary	empire	erik	expensise
##	0.61	0.61	0.61	0.61	0.61
##	farflung	financier	forced	foreign	forvaltnings
##	0.61	0.61	0.61	0.61	0.61
##	fought	frederik	free	fringe	heart
##	0.61	0.61	0.61	0.61	0.61
##	incentive	industrier	investors	koppabergs	laval
##	0.61	0.61	0.61	0.61	0.61
##	left	londonbased	lundberg	managed	match
##	0.61	0.61	0.61	0.61	0.61
##	matchs	nobel	nobl	originally	ousted
##	0.61	0.61	0.61	0.61	0.61
##	outside	penser	predators	prevent	protect
##	0.61	0.61	0.61	0.61	0.61
##	providentia	raid	restricted	secure	skanska
##	0.61	0.61	0.61	0.61	0.61
##	skbs	skf	skfr	skps	small
##	0.61	0.61	0.61	0.61	0.61
##	smbs 0.61	stora 0.61	swedens 0.61	swedish 0.61	taken 0.61
##					
##	thre 0.61	tycoon 0.61	undertaken 0.61	volv 0.61	volvo 0.61
##					
## ##	wallenberg 0.61	wallenbergs 0.61	wrested 0.61	zurichbased 0.61	voting 0.60
##	0.61	0.61	0.01	0.61	0.60

findAssocs(matrix, "mln", 0.6)

^{## \$}mln

^{##} dlrs

^{## 0.74}